● AI 深度解读 · 图表重绘 | bioRxiv · 2026 | scRNA-seq | compression PCR | dynamic range compression

Compression Sequencing enables ultra-sensitive and scalable scRNA-seq

压缩测序：把对数变换做进分子里，让测序预算从高丰度基因流向稀有转录本

Yan Yan · Mingjie Dai

DOI 10.64898/2026.09.01.748706 | 5 张原文图表 | 11 页 | 查看原文 PDF

一句话读懂

用「限量引物」把非对称 PCR 改造成分子对数编码器（输入 5 个数量级 → 输出 <1 个数量级，R^2=0.99），在 500–2,000 基因面板上把测序效率提高 100–140 倍、shallow 模式降低 200–500 倍深度：稀有基因 UMI 提高 2–5 倍，0.7 M reads 仍保住 79% DEG 与 ARI 0.78，AML 亚型判读成本估计 <$10/样本。

100 – 140×
测序效率提升
11 M vs 140 M reads 达到相似饱和度

1/200×
Shallow 模式深度
0.7 M reads, <170 reads/cell

2 – 5×
稀有基因 UMI 提升
低丰度基因平均 1.9×，最高 5×

$<10
AML 单样本成本（作者估计）
测序 <$5/样本，2–3 万细胞

01

结论先行：这篇论文把「对数压缩」从算法搬进了试管

测序仪很大程度上不是在"测量"，而是在**重复采样**：一个细胞里约 30 万–50 万个 mRNA 分子，不到 10% 的高表达基因占掉 >95% 的读段，而占基因数 70% 的中低丰度基因只分到 <1% 的读段、dropout 率 50–100% 原文 p.2↗。要忠实覆盖稀有转录本需要 1–2 M reads/cell，实际研究只给 1–2 万 reads/cell，差 50–100 倍 原文 p.2↗。作者（Rice University，Yan Yan & Mingjie Dai）的解法不是去丰度、不是做 panel 富集，而是**改写「丰度 → 读段」这条映射本身**：把非对称 PCR 的"限量引物"条件推到极致，让最终产物浓度与模板浓度的**对数**成正比，于是 5 个数量级的输入被压成 <1 个数量级（R^2=0.99）原文 p.3↗。

把这一步作为 "add-on" 接在 10X 3′ 文库上，作者在 500–2,000 基因面板上报告：11 M reads 达到与 140 M reads 相近的饱和度（**100–140× 效率**），稀有基因 UMI 提高 **2–5×**；同一份压缩文库只测 0.7 M reads（**1/200×**，<170 reads/cell）仍保住 79% 的 DEG 覆盖与 ARI 0.78 的细胞分型 原文 p.4–7↗；在三例 AML 临床样本上复现了 FAB 亚型判读，并把测序成本估到 <$5/样本 原文 p.7–8↗。

一句话：**它卖的不是"更深的测序"，而是"更聪明的读段分配"**——用一管引物，把测序预算从"已经被看得太多"的基因手里拿走，交给"几乎没被看到"的基因。

100 – 140× 测序效率提升 11 M vs 140 M reads 达相近饱和度	1/200× Shallow 模式深度 0.7 M reads, <170 reads/cell	2 – 5× 稀有基因 UMI 提升 低丰度基因平均 1.9×，最高 5×	$<10 AML 单样本成本（作者估计） 测序 <$5/样本，2–3 万细胞

表 A　五条主结论与证据强度（"本报告判读"一栏为解读，非原文表述）

主结论	原文数字	证据位置	本报告判读
cPCR 是一个可定量的"分子对数编码器"	输入 5 个 log → 输出 <1 个 log（>10,000 倍压缩），端点信号 vs 输入 R^2=0.99；96 重靶标中 69/96（72%）R^2>0.95	p.3–4、Fig. 1j–m 原文 p.3	**最硬的一环。**化学原理清楚（两相扩增）、公式可检验、在 5 个数量级上线性；但 96 重里 28% 靶标不达标，说明"多重化成功"仍依赖逐对引物
接到 10X 3′ 文库上能压缩 1,000 倍动态范围	60 靶标试点：barcode 覆盖 >99%、动态范围 ↓1,000×；148 靶标：on-target 40%→70%，高丰度抑制 500–1,000×、稀有富集 5–10×	p.4、Fig. 2c–d 原文 p.4	**成立但剂量小。**这里报告的压缩/富集倍数是 10^2–10^3，与摘要的 "100× efficiency" 不是一个口径，后者混合了 panel 富集
500 基因面板：读段减少 1/13 而稀有基因 UMI 增加 2–5×	11 M vs 140 M reads；低丰度读段占比 1.5%→7.4%，高丰度 43%→22%；UMI 覆盖中位数 64% vs 36%；两段模型过渡点 370 reads ≈150 UMIs	p.4–5、Fig. 2e–k 原文 p.5	**数字自洽且信息量最大的一张图。**两段模型把"哪里压缩、哪里不压缩"讲清楚了，也顺带暴露了高丰度基因 UMI 反而变少的代价
2,000 基因面板在 1/3 测序深度下多检出 21% DEG，且更可重复	51 M reads；稀有基因 10.6× reads / 2.5× UMIs；UMI 覆盖 67% vs 27%；四个细胞类型合计 DEG 554→669；两供体共有的"仅压缩检出" DEG 占 45% vs 10X-only 21%	p.6、Fig. 3 原文 p.6	**论证链设计得最好的一条。**"额外 DEG 是否假阳性"用跨供体重复率回答（45% vs 21%），比单看 DEG 数有说服力；但 Log2FC 斜率 0.70 的衰减仍需解释
1/200× 深度仍可做细胞分型与 DEG；AML 亚型可复现	0.7 M reads：barcode >96%、ARI 0.78（T+NK 合并后 0.97）、DEG 覆盖 79%（1/100× 下采样的 10X 只有 <15%）；AML 600–800 reads/cell ARI 0.80–0.82，80 reads/cell 仍 85–92% 准确率	p.6–8、Fig. 4–5 原文 p.7	**最有转化价值、样本最薄的一条。**PBMC 只用了 2 个供体、AML 只有 3 例，且没有独立病理/随访验证；"复现诊断"是 3/3 但 n 太小

数字均转录自原文正文与图；"本报告判读"为解读，已在正文用 ［推断］ 标注。

读这份报告前必须知道的边界

本次提供的 PDF 只有 **11 页主文 + 参考文献**：Methods、Supplementary Note 1–3、Supplementary Fig. 1–4、Extended Data Fig. 1–7、Supplementary Table 5 都**不在这个文件里**。因此本报告能核对的只有正文与五张主图；凡是涉及"反应条件怎么定、引物怎么筛、统计检验怎么做、成本怎么算"的细节，都属于**本文件无法核实**。文中引用 Extended Data / Supplementary 的地方，本报告只能转述作者说法，不能当作已验证证据。

02

问题：测序预算被一小撮高丰度基因"征税"

scRNA-seq 的成本结构有一个非常反直觉的形状：**真正决定"能不能看见稀有转录本"的不是测序仪的通量，而是丰度分布的动态范围。**作者引用的数量级是：人细胞内 mRNA 丰度跨 5–6 个 log；在典型 scRNA-seq 里，低于中位表达的基因（约占基因数 70%）合计只占 <1% 的读段，dropout 率 50–100%；而 <10% 的高表达基因吃掉 >95% 的读段 原文 p.2。这意味着**你付的钱里绝大部分花在重复确认"β-actin 还是很高的"**。

这个约束在"细胞数 × 深度"的乘积上是硬的。作者算了一笔账：10 M 细胞 × 50,000 reads/cell，仅测序就要 $120,000–250,000（UG100 或 NovaSeq X）原文 p.2；而虚拟细胞模型需要的训练集是 30–100 M 细胞 原文 p.2。所以问题不是"测序仪不够快"，而是"每次读取的边际信息量在下降"。

已有的四条路线各自卡在不同的地方 原文 p.2↗：

- **靶向 panel 富集**（targeted Perturb-seq、HyPR-seq 等）：只测选中的基因，确实省，但它**不改变 panel 内部的动态范围**——panel 里高丰度基因依然霸占读段；
- **杂交动力学归一化**（equalized cDNA library、normalized cDNA）：靠复性速率差压缩丰度，但只能削弱、不能定量，且序列依赖偏差大；
- **DSN（双链特异核酸酶）消化**：同样依赖动力学，偏差与不可控性更强；
- **直接加大深度**：线性花钱，且在高丰度端边际收益极低。

> **[背景] 为什么这其实是一个"信号处理"问题**
>
> 把每个基因的丰度当成输入信号 x，测序仪的输出是"按 x 比例分配读段"，等价于一个**线性 ADC**：输入动态范围 5 个 log，而读段预算只有有限的比特数，于是小信号被量化噪声（dropout）淹没。作者的做法是在采样之前插一级**对数压缩（log companding）**：把 10^5 的输入范围压到 <10，再用同一套量化器去量化——这正是音频压扩、图像 gamma、HDR 编码（LogLuv）在做的事，作者也明确引了 Shannon、Huffman、Golomb 与 LogLuv 编码 原文 p.2↗。区别只在于：他们不是用电路，而是用**一管限量引物**实现这个非线性。

理解这一点，就能理解本文真正的主张边界：**它不增加细胞里的分子数，也不增加总读段数；它只改变读段在基因之间的分配**。所有"更灵敏"的说法，都必须读成"在同样的总预算下，稀有基因分到的读段更多"。这个区别在后面批判性评估里会反复出现。

03

核心思想：用「限量引物」把指数扩增变成对数读出

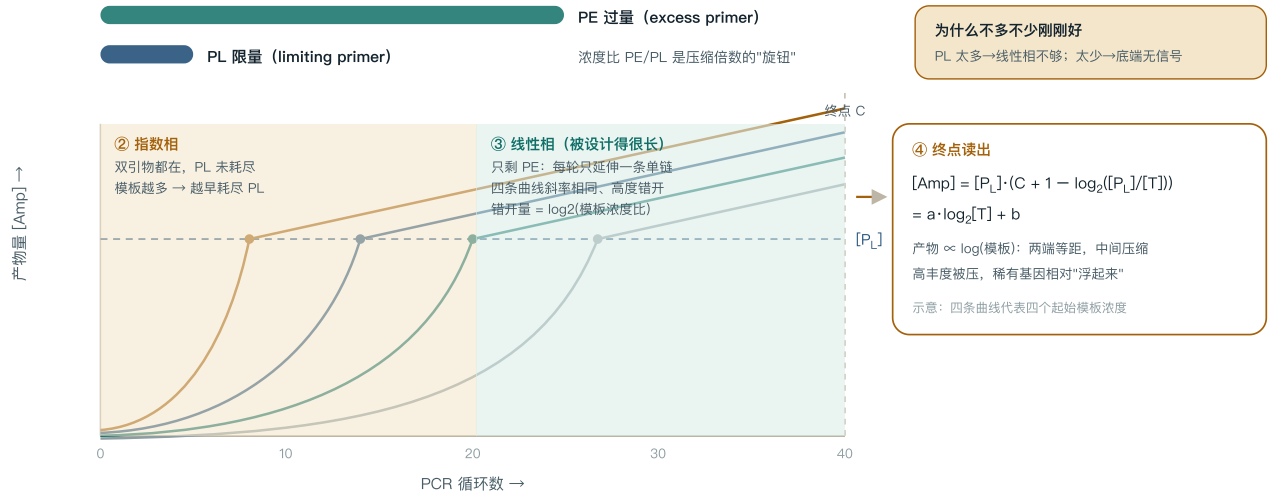
cPCR 的化学基础是**非对称 PCR**（asymmetric PCR / LATE-PCR）原文 p.2↗：正向与反向引物不等量。作者的关键改动是把"少量引物"从"副产品手段"变成**定量的标尺**，并刻意让反应进入一个很长、很稳的第二相。

反应分两段。第一段（指数相）：两种引物都在，扩增是常规的指数增长，直到**限量引物 PL 被耗尽**。模板越多，PL 越早耗尽，留给第二段的时间越长。第二段（线性相）：只剩过量引物 PE，每一轮只延伸一条单链，产物**线性**增长。把两段接起来，终点产物是：

$$[\text{Amp}] = [P_L]\cdot(C + 1 - \log_2([P_L]/[T])) = a\cdot\log_2[T] + b$$ 原文 p.3 Fig.1g↗

直觉版本：**指数相的长度本身就是 $\log_2([P_L]/[T])$ 轮**，而总循环数 C 是固定的，所以"线性相 = C − 指数相"对 log[T] 是线性的。作者特别强调这与常规 qPCR 的"短暂线性相"不同——qPCR 的线性相是试剂耗尽的副产物，而这里是被设计成**贯穿剩余全部循环**的定量区间 原文 p.2↗。

● AI 重绘示意图（非原文图）　机制重绘自 Fig. 1f–i 与公式 1g · 分步演示（← / → 或点数字切换）



1 先把两种引物做成不对称的

过量引物 PE 决定"线性相能跑多快"，限量引物 PL 决定"指数相什么时候停"。两者的浓度比是这套方法的**唯一主旋钮**：PE/PL 越大，压缩越狠；作者在原理验证里用 50，在高度多重化时降到 10，并进一步把 PL 降到 7.5 nM 原文 p.3–4↗。

2 指数相：模板越多，越早耗尽 PL

这一段与普通 PCR 无异。关键性质是**指数相的长度由模板浓度决定**：起始模板越高，到达 PL 耗尽所需的循环数越少，因此剩余给线性相的循环数越少——但注意，模板高时线性相期间每轮新起的单链也更多，两个效应合并后，终点值仍单调上升，只是上升被 log 压平。

3 线性相：把"指数"换成"线性"，信息就留在 log 里

PL 耗尽后只剩 PE，产物线性增长。四条曲线在图上变成**彼此平行、高度错开**的直线（Fig. 1i 的原始观察）：错开的距离正比于 $\log_2$(模板浓度比)。这就是"对数编码"在物理上的样子——不是算出 log，而是让反应**只跑 log 那么多轮指数**。

4 终点读出：产物浓度是模板对数的仿射函数

公式里 a、b 是常数 原文 p.3↗。作者在合成模板上实测：输入跨 5 个 log，端点信号与之线性相关 R^2=0.99，整个 5 log 区间被压成 <1 log 原文 p.3↗。注意这个变换是**逐基因独立**的：反应不关心"你是高表达还是低表达"，只关心"你和我的 PL 谁先耗尽"。

这张图要记住的一点：压缩不是靠"识别高丰度基因再抑制它"，而是靠一个**饱和机制**——PL 被耗尽的时刻本身就是丰度的函数。因此它对所有基因一视同仁，也就不需要事先知道哪些基因该压（这正是作者强调的"unbiased"）原文 p.2↗。

作者把 cPCR 的性质归纳为三条 原文 p.2↗：**(i) 无偏**——压缩机制不依赖对表达水平的预设；**(ii) 定量且逐基因独立**——多重反应里每个靶标各自完成对数压缩，保留各自的定量关系；**(iii) 可调**——压缩程度由 PL 浓度等条件控制，可以在"省测序"与"保灵敏度"之间选点。这三条里，第 (ii) 条是最强的假设，也是后面批判性评估要重点查的地方：**"逐基因独立"要求每个引物对的 a、b 足够接近，否则跨基因比较会被引物效率污染。**

与既有方法的差别（读文献时最容易混淆的三点）

① **不是"抑制高丰度"（suppression），是"重标定"（re-scaling）。**DSN 与复性归一化是**去除**高丰度分子，会损失绝对定量；cPCR 不丢分子，只让每个分子的"读段权重"变成 log 函数。② **不是 LATE-PCR 的直接套用。**LATE-PCR 关注的是"线性相做熔解曲线/定量"，本文关注的是"线性相的长度差编码了 log 丰度"，并把它推到 >5 个数量级与几百重靶标。③ **与 targeted panel 是正交的两件事。**cPCR 必须靠引物才能实施（因此天然是 panel），但 panel 只是它的"载体"；panel 决定"测哪些基因"，压缩决定"panel 内部怎么分配读段"。这个区分在第 11 节会成为主要批评点。

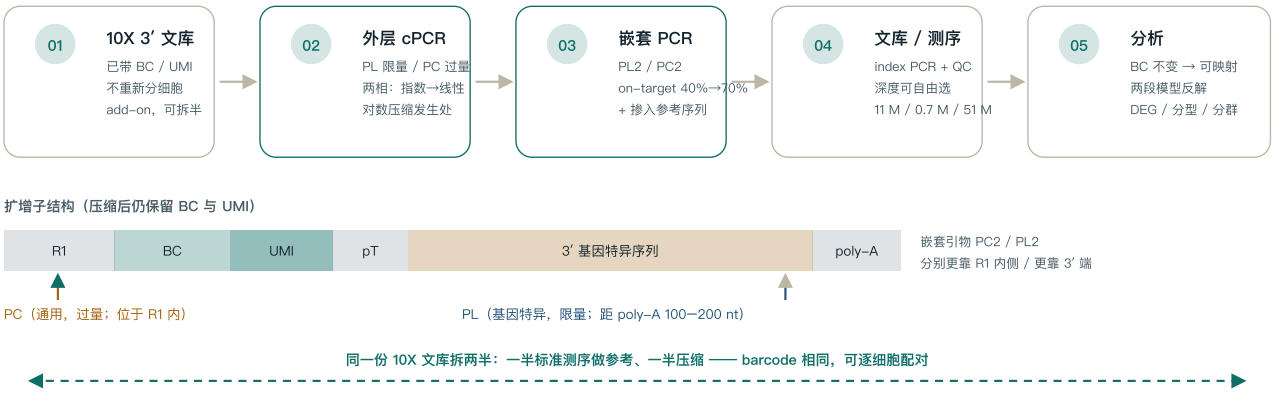
04

方法：把一个现成的 10X 文库变成「可压缩文库」

把 cPCR 接到 scRNA-seq 上的难点非常具体：**扩增产物必须同时携带细胞身份（barcode）与分子身份（UMI）**，否则压缩之后无法回到单细胞。作者的 "add-on" 设计如下 原文 p.4 Fig.2a：

- **基因特异引物 PL** 落在 mRNA 转录本上、poly-A 位点上游 100–200 nt 处；
- **通用引物 PC** 放在 Illumina read primer（R1）里，方向朝 barcode 一侧；
- 于是扩增子 = R1 + **barcode + UMI** + poly-T + 一段基因特异序列，压缩后的分子仍可被 CellRanger 按 barcode/UMI 计数；
- **嵌套 PCR（PL2/PC2）**替代原来的"单链转双链"步骤，把 on-target 读段占比从 40% 提到 70% 原文 p.4；
- 因为 PC 是所有基因共享的，在 500 基因面板里 PC/PL ≈ 500 × 15 = 7,500 倍 原文 p.4——这个极端的不对称逼着作者重做引物设计（热力学 + 二聚体最小化，改编自 SADDLE 的模拟退火算法）原文 p.4。

AI 重绘示意图（非原文图） 流程重绘自 Fig. 2a–b 与 Fig. 1f · 悬停各阶段查看说明



这张图的要点不是"五个步骤"，而是 01 与 05 之间的那条虚线：压缩发生在 barcode 已经打好之后，因此参考数据与压缩数据**共享同一套细胞编号**，可以做到逐细胞、逐基因的配对比较——这是本文所有"R^2=0.94/0.95/0.98"类论证能够成立的方法学前提。换一种说法：它不是一个新的单细胞平台，而是**一个可以随时插入现有流程的"读段重分配插件"**。

表 B　可复现参数一览（全部转录自正文；Methods 不在本 PDF 内，故无法补全实验细节）

环节	参数 / 规模	出处
原理验证（合成模板）	PE/PL = 50；Taq + TaqMan 探针读出；输入 10 pM–100 aM（5 个 log）；每档 3 重复	p.3 Fig.1j–k
多重化优化	Taq 聚合酶 + Bio-Rad SsoAdvanced 抑菌缓冲液；4 重靶标测试	p.3
8 靶标验证	PL = 15 nM，PE/PL = 10；R^2=0.94–0.99	p.4
96 / 192 靶标	96 个能量平衡引物，10 fM–100 aM；69/96 R^2>0.95（83% R^2>0.90）；人+酵母 96+96 双物种 R^2>0.98	p.4 Fig.1l–m
单细胞面板（试点）	60 靶标（无嵌套）；barcode 覆盖 >99%（10 万 reads 内）	p.4 Fig.2c
单细胞面板（148 靶标）	嵌套 PCR；on-target 40%→70%；高丰度抑制 500–1,000×、稀有富集 5–10×	p.4
500 基因免疫面板	486 基因 / 533 个 3′ 端 / 512 对引物（成功率 93%，覆盖 457 基因）；PL = 7.5 nM；测 11 M reads	p.4
2,000 基因面板	2,086 基因（占总丰度 18.7%）；2,395 个 3′ 序列；4 个 ~500 基因子面板；186 个重复靶标；测 51 M reads	p.6
参考数据集	10X 3′ mRNA；140 M reads；4,200 个细胞；≈33,000 reads/cell	p.4
Shallow 模式	0.7 M reads（1/200×）；<170 reads/cell	p.7
AML 临床样本	Fluent（Illumina）PIP-seq；4 个样本（S0 健康、S1/S2 AML-M4、S3 AML-M2）；参考 38,000 reads/cell；压缩 600–800 reads/cell（1/50–60×）；最低下采样到 80 reads/cell（1/500×）	p.7–8
AML 面板	1,000 基因免疫标记 panel（952 基因，1,084 靶标）	p.7
分析工具	CellRanger 比对 + 自定义程序；Harmony 共聚类；preseq 估计文库复杂度；两段模型拟合（Supplementary Note 3）	p.6–7

表中缺的是"怎么定"：引物筛选阈值、反应体积/循环数、纯化方式、测序饱和度口径、统计检验与多重比较校正，都在未提供的 `Methods` 里。

ADD-ON 的隐性成本：这张流程图表没画的部分

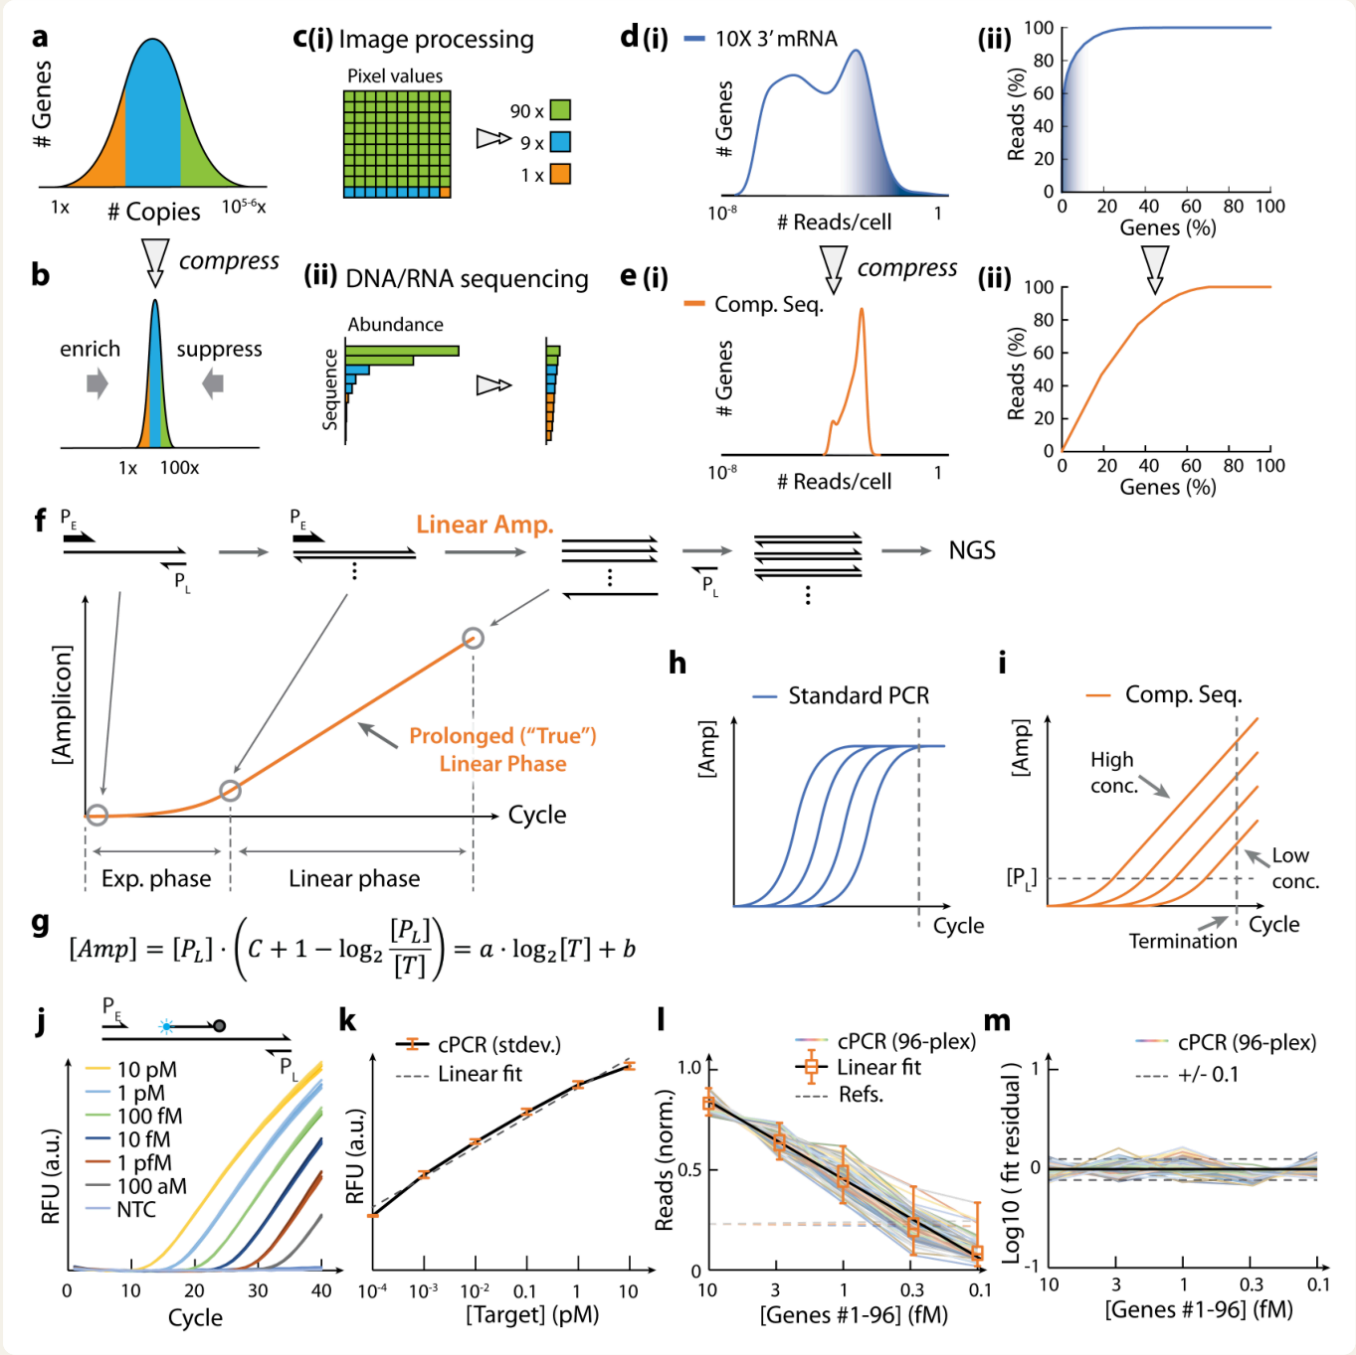
流程看上去只多了两步 PCR，但真正的成本在**引物池**：500–2,000 对引物要设计、合成、验证、平衡（原文 96 重的成功率只有 72%，500 基因的面板引物成功率 93%）；嵌套 PCR 多一轮循环与纯化；每个新 panel 都要重新做能量平衡与二聚体优化。作者的"<$5 测序成本"只覆盖测序本身，**不含引物与人力** 原文 p.8↗。这一点在读成本结论时要一直记着。

05

第一张图：先证明"分子真的能做对数变换"

Fig. 1 是全文的地基：如果 cPCR 不是精确的 log 编码器，后面所有单细胞结论都不成立。它分三层论证——**概念**（a–e：为什么压缩读段分配是可行的）、**机制**（f–i：两相扩增为什么等于对数）、**实测**（j–m：在合成模板与 96 重体系里到底准不准）。

• FIGURE 1　原文 Figure 1 · p.3 · 混合裁切 · 来自 PDF 原始页面 · 1360×1364 px　原文 p.3 ↗



原文图注 · P.3

"Figure 1. Compression Sequencing enables accurate logarithmic transform and dynamic range compression in highly multiplexed assay."

逐面板解读

A–B **压缩前后的基因丰度分布**：横轴是拷贝数（1× 到 10^{5-6}×），纵轴是基因数。a 是原始分布——典型的右偏长尾；b 是压缩后——分布被挤成一个窄峰（1×–100×），左右两个灰色箭头写明机制：**左侧富集（enrich）、右侧抑制（suppress）**。这是概念图，不含量化数据。原文 p.3 ↗

C **跨领域的类比**：(i) 图像处理里像素值有 90×/9×/1× 三级，压缩后统一；(ii) 测序里各序列的丰度条长短相差几个 log，压缩后差不多齐平。作者用这个面板把"压缩测序"接到 Shannon 以来的编码传统上——它不是生物学的发明，而是把信号处理的一条老原则搬进了试管 原文 p.2↗。

D **问题有多大（真实 10X 数据）**：(i) PBMC 单细胞数据里基因表达呈双峰分布，横轴跨约 5 个 log；(ii) 累积读段曲线——**前 10% 的基因吃掉约 80% 的读段**，剩下 90% 的基因分 20%。这两张小图就是全文的成本论证：阴影区那撮基因决定了测序深度，却几乎不提供分型信息。原文 p.3↗

E **压缩后会长什么样（模拟）**：(i) 分布变成单峰窄分布（注意横轴仍是 10^{-8}–1 的同一刻度）；(ii) 累积读段曲线接近线性——读段按基因数均匀分配。这是**模拟**，不是实验；它的作用是定义"理想压缩"的靶子。原文 p.3↗

F **cPCR 的分子流程**：PE（过量）与 PL（限量）夹住同一段模板 → 双引物指数扩增（Exp）→ PL 耗尽后只剩 PE 延伸，产生单链（Linear Amp.）→ 转成双链 → 上机。注意图里**"Prolonged ('True') Linear Phase"**的措辞：作者刻意把它与 qPCR 里"试剂耗尽的短暂线性段"区分开。原文 p.3↗

G **转换公式**：$[Amp] = [P_L]\cdot(C + 1 - \log_2([P_L]/[T])) = a\cdot\log_2[T] + b$。它把"两相扩增"翻译成一个仿射变换：**斜率 a 由循环数与引物化学决定，截距 b 由 PL 浓度决定**。这个公式是本文所有"定量"主张的源头。原文 p.3↗

H–I **决定性的对照**：h 是标准 PCR——不同起始浓度的曲线都是 **S 形**，终点全部饱和到同一平台，所以终点读不出起始量（只能靠 Ct 值，而 Ct 在高循环数下不再线性）；i 是 cPCR——不同起始浓度变成**一组平行直线**，在固定终点循环处读数，高低由起点决定。这一对面板是全文最漂亮的地方：**同样一台 qPCR 仪、同样的终点读数，只有引入限量引物，输出才从"饱和"变成"对数"**。原文 p.3↗

J **原理验证的实时曲线**：10 pM 到 100 aM 五个数量级 + NTC，每档 3 重复。可以看到 (1) 浓度越低曲线越晚起（指数相更长）；(2) 起得晚的最终也低，但差距被压得很小；(3) NTC 也有微弱信号——qPCR 的典型背景。原文 p.3↗

K **端点读数 vs 输入浓度**：双对数坐标上是一条直线，跨 10^{-4}–10^{1} pM（5 个 log），R^2=0.99。**这是"分子对数编码器"成立的直接证据**：输入变化 10^5 倍，输出只变化 <10 倍 原文 p.3↗。原文 p.3↗

L **96 重体系的准确性**：每一条彩色细线是一个靶标，横轴是靶标浓度（10 fM → 0.1 fM，即 100 aM），纵轴是归一化读段数。理想情况下 96 条线应该重合——图里确实收拢成一条带，但注意**带很宽**，且浓度越低越散。原文 p.4↗

M **拟合残差**：$\log_{10}$ 残差基本落在 ±0.1 以内（虚线），换算成线性尺度是 CV<30%。这是对"定量精度"最接近正面回答的面板——30% 的 CV 对 UMI 计数够用，对需要 2 倍效应的实验就偏粗了。原文 p.4↗

读图注意：这张图证明了什么、没证明什么

它证明的是：在纯化的合成模板 + 单重/96 重条件下，终点信号确实与模板浓度的 log 线性相关，且这种关系在 5 个数量级上成立。**它没有证明**：① 在真实细胞裂解液、几千种 cDNA 混杂的背景下还能保持；② 每个基因的 a、b 足够一致（图 I 的带宽本身就是反证的一半）；③ 压缩后的"读段数"仍然可以跨基因比较。**第 ③ 点是全文最容易被读者自行补全、但原文并未直接证明的假设** [推断]。另外，Fig. 1k 的 R^2=0.99 是**单重**结果，多重化的 96 重里只有 72% 靶标达到 R^2>0.95 原文 p.4↗——两个数字经常被混着引用。

这张图在论证链上的位置

它承担的是"**原理可行性**"这一环，而且承担得很干净：用 qPCR 仪这种人人有的设备、用合成模板这种人人能重复的体系，把"两相扩增 = 对数编码"从一个比喻变成一个可测的斜率。后面所有单细胞实验都建立在这个斜率上；如果斜率会随背景漂移，后面的一切都要重新标定。

多重化的代价在这张图里已经露头：96 个"能量平衡"的引物、未做逐对优化的情况下，只有 **69/96（72%）**靶标达到 R^2>0.95，**83%** 达到 R^2>0.90 原文 p.4↗；两物种混合实验（96 人 + 96 酵母）里固定组信号保持恒定、变化组 R^2>0.98 原文 p.4↗。这说明：**cPCR 本身是稳的，但"多重化"这一步会掉靶**——而掉靶不是随机的，后面会看到它与引物效率、丰度都有关。

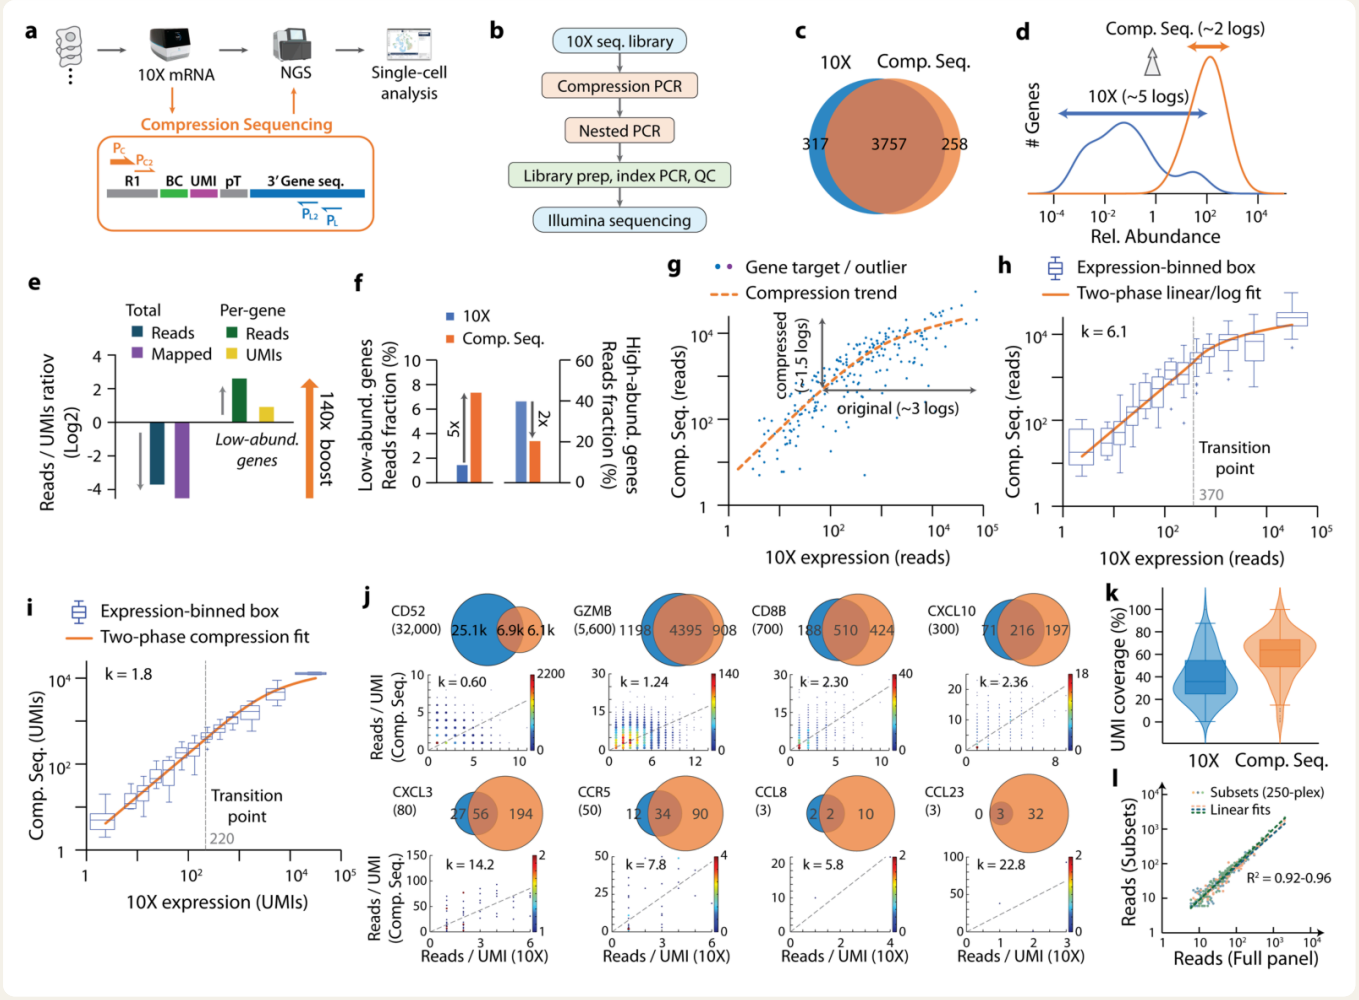
06

第二张图：500 基因面板上的"Deep Sequencing"

这是全文信息量最大的一组实验。设计是：在同一个 PBMC 的 10X 3′ 文库上，先测一份 140 M reads 的标准参考（4,200 个细胞，≈33,000 reads/cell），再做一份 500 基因面板的压缩文库，测到 11 M reads（**约为参考的 1/13**），然后逐基因、逐 UMI 地比较 **原文 p.4**↗。

面板本身值得单独看：作者从 RefSeq 里所有注释剪接异构体出发，取 486 个基因的 **533 个唯一 3′ 端序列**，设计出 512 对 cPCR 引物（**成功率 93%**，最终覆盖 457 个基因）**原文 p.4**↗。也就是说，从一开始就有约 7% 的基因"设计不出来"或"验证不过"——这是 panel 方法的结构性偏差，原文没有分析失败基因是否集中在某些丰度段。

● FIGURE 2　原文 Figure 2 · p.5 · 图像块裁切 · 来自 PDF 原始页面 · 1600×1182 px　原文 p.5 ↗



原文图注 · P.5

> "Figure 2. Compressed "Deep Sequencing" with >100x improved efficiency reveals 2-5x more transcripts in low-abundance genes"

逐面板解读

A　**Workflow 与扩增子结构**：10X mRNA → Compression Sequencing → NGS → 单细胞分析。放大框里画的是引物位置：**P_C（通用过量）在 R1 一侧、P_L（基因特异限量）在 3′ 基因序列一侧**，中间依次是 BC（barcode）、UMI、pT（poly-T）。这解释了为什么压缩后还能按细胞计数。原文 p.5 ↗

B　**四步实验流程**：10X 文库 → Compression PCR → Nested PCR → 文库制备/QC → Illumina 测序。嵌套 PCR 是"可扩展性"的关键补丁（见文字部分）。原文 p.5 ↗

C　**Barcode 覆盖**：Venn 图，两套数据共享 **3,757** 个 barcode，10X 独有 317、压缩独有 258。原文另称"从 10 万 reads 起 barcode 覆盖 >99%" 原文 p.4 ↗。读法上要注意：**共享 3,757 并不等于"99% 覆盖"**——两者来自不同的稀释曲线口径，不能互换引用。原文 p.5 ↗

D　**动态范围压缩的直接可视化**：蓝线是 10X 的丰度分布（横跨约 5 个 log），橙线是压缩后的（约 2 个 log），图上标了 **~5 logs → ~2 logs**。这是全文最直观的一张"前后对比"，对应文字里的"~1,000 倍动态范围压缩"。原文 p.5 ↗

E **总读段与逐基因读段的双向变化（$\log_2$ 尺度）**：Total 一列是负值（总 reads 约 −4.2、mapped 约 −4.6），Per-gene 一列是正值（reads 约 +2.7、UMIs 约 +0.9），右侧橙色箭头写 **140× boost**。这是全文最关键、也最容易被误读的一张柱状图：**它把"总预算减少"和"单基因得到更多"并列**，图注称两者合并为 140× overall enrichment。注意 140 不是"精度提升 140 倍"：把两个 $\log_2$ 比值粗乘约得 10^2 量级，精确分解依赖未随本文件提供的 Supplementary Note 3 [推断]。原文 p.5↗

F **读段重新分配（箱内视角）**：低丰度基因的读段占比 **1.5% → 7.4%（5×）**，高丰度基因 **43% → 22%（约 2×）**。这才是在 panel **内部**能测到的纯压缩效应，量级是 2–5×，与 headline 的 100× 差两个数量级（见第 11 节）。原文 p.5↗

G **逐基因散点**：横轴 10X 表达（reads），纵轴压缩后 reads。虚线给出压缩趋势，图中标注"compressed（~1.5 logs）vs original（~3 logs）"——原始 3 个 log 的跨度被压到 1.5 个 log。低丰度端（左下）明显偏离趋势线向上，即"被放大"。原文 p.5↗

H **分箱 + 两段拟合（reads）**：把 g 的散点按丰度分箱画箱线图，再叠一条两段模型曲线：**低丰度段斜率≈1（线性放大），高丰度段斜率<1（对数压缩）**，拟合参数 k=6.1，**过渡点标在 370 reads**。这是"压缩是自靶向的"这一解释的原始出处。原文 p.5↗

I **同上的 UMI 版本**：纵轴换成压缩后 UMI，k=1.8，过渡点 **220 UMIs**。UMI 的压缩比 reads 温和——因为 UMI 计数还叠了一层"读段随机抽样"，稀释了压缩。**这一张是"灵敏度"主张的核心图**：低丰度端 UMI 被抬高。原文 p.5↗

J **UMI 层面逐基因解剖（8 个例子）**：每个基因给出 UMI 交集（蓝=10X、橙=压缩）与"每 UMI 的读段数"散点，右下角 k 是压缩因子。左侧高丰度基因（CD52 32,000 UMIs，k=0.60）压缩后 UMI **反而少了**（25.1k+6.9k → 6.9k+6.1k，约 32k→13k）；右侧稀有基因（CXCL3 80、CCL23 3）压缩后 UMI 多出约 3–12 倍（k=14–23）。**这张图是全文最诚实的图**：它自己把"信息不是单调增加，而是重新分配"画了出来。原文 p.5↗

K **UMI 覆盖率的总体分布**：小提琴图，10X 中位数 **36%**，压缩 **64%**。注意这是"互相交集"估计出的覆盖率（以两套数据 UMI 集合的并/交推算），**不是绝对真值**——原文未在本 PDF 中说明估计公式。原文 p.5↗

L **面板规模的稳健性**：整块 500 基因面板 vs 三个 250 基因子集，R^2=0.92–0.96。说明"抽掉一半靶标"不会显著改变压缩后的读数——这是对多重化互相干扰的一个间接检验。原文 p.5↗

读图注意：三个最容易踩的坑

① **140× 不是"测量精度提升 140 倍"。**它是"总读段省了约 13–18 倍"乘"每个基因分到的读段多了约 6.5 倍"的乘积；前者来自"只测 457 个基因"，后者才部分来自压缩。把它读成"灵敏度 ×140"会高估方法本身。

② **UMI 覆盖率 64% vs 36% 不是"压缩让分子变多"。**分子数没变，变的是"被抽样到的概率"。而覆盖率的中位数掩盖了分布：高丰度基因的覆盖率在压缩后是下降的（见 j 的 CD52）。

③ **过渡点 370 reads / 150 UMIs 是拟合出来的，不是设计出来的。**它取决于 PL 浓度、细胞数、panel 组成与测序深度；换一个 panel 或换一个细胞数，这个点会移动。原文没有给出"如何为新 panel 估计过渡点"的配方（Supplementary Note 3 不在本文件内）。

这张图真正的说服力在哪

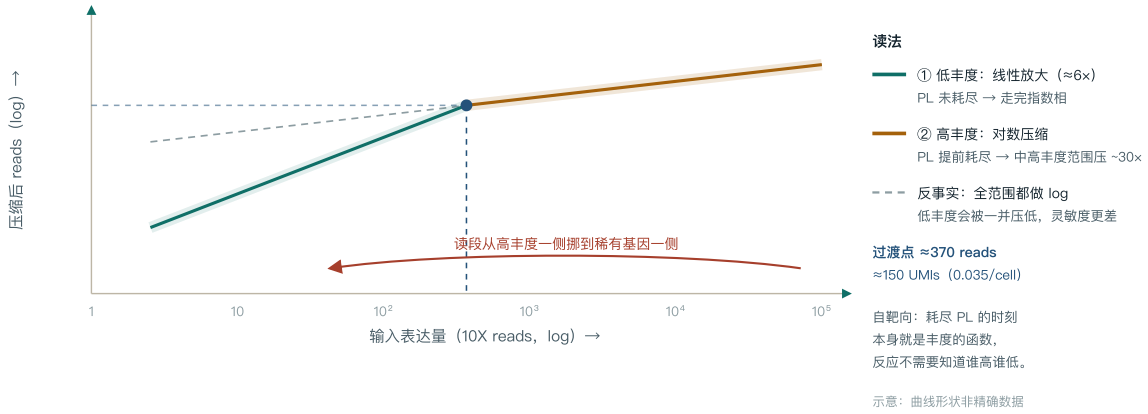
不在 140×，而在 **j 面板的诚实**：作者主动展示了 CD52 这类高丰度基因损失了一半以上的 UMI。一个只想卖方法的人不会放这张图。从证据角度，这反而让"信息重新分配、而非凭空增加"的核心叙事可信——读者可以用它反推方法的适用边界：**如果你关心的是高丰度基因的精确计数，压缩是负收益；如果你关心的是稀有基因的检出与分型，压缩是正收益。**

机制：压缩为什么是「自靶向」的

Fig. 2h–i 的两段模型值得单独拆开讲，因为它是全文唯一一个"机制解释 + 定量拟合"同时给出的地方，也是所有"为什么能省"论证的枢纽。

模型只有一句话：**低丰度基因在整个反应里都没能让 PL 耗尽，所以它走完指数相、产物与输入成正比（等价于普通 PCR）；高丰度基因提前耗尽 PL，被迫进入对数段。**于是压缩这件事自动只作用于"高丰度那一侧"——不需要事先知道哪些基因高，也不需要按表达水平做任何预设。作者称这一点为 "unbiased" 原文 p.2↗，从机制上说确实是自洽的。

● 数据转录自 FIG. 2H–I（未重新分析） 两段模型示意 · 过渡点与倍数取自原文 p.4–5



读法：两段线都是"读段随输入增长"，但斜率不同。低丰度段斜率≈1（输入翻倍、读段翻倍，跟普通 PCR 一样）；高丰度段斜率<1（输入翻 100 倍，读段只翻几倍）。**虚线是个"反事实"：如果没有这个拐点、全范围都做 log，低丰度基因会被一并压低，灵敏度反而更差**——两段结构才是这个方法的精髓。

把 Fig. 2e–k 的数字按这个模型排一遍，逻辑就清楚了：

- **低丰度端**：线性放大 ≈6× 读段；再叠加"只测 panel 内基因"带来的读段集中，最终单基因读段增益约 6.5×，稀有基因的 UMI 平均 +1.9×、最高 +5× 原文 p.4↗。
- **高丰度端**：读段被压 30× 的动态范围，高丰度读段占比 43%→22% 原文 p.4↗；代价是这些基因的 UMI 减少（CD52 例）。
- **整体**：总 reads 约 1/13–1/18 而每基因 reads 约 6.5×，作者表述为"140× 总体富集" 原文 p.5↗。

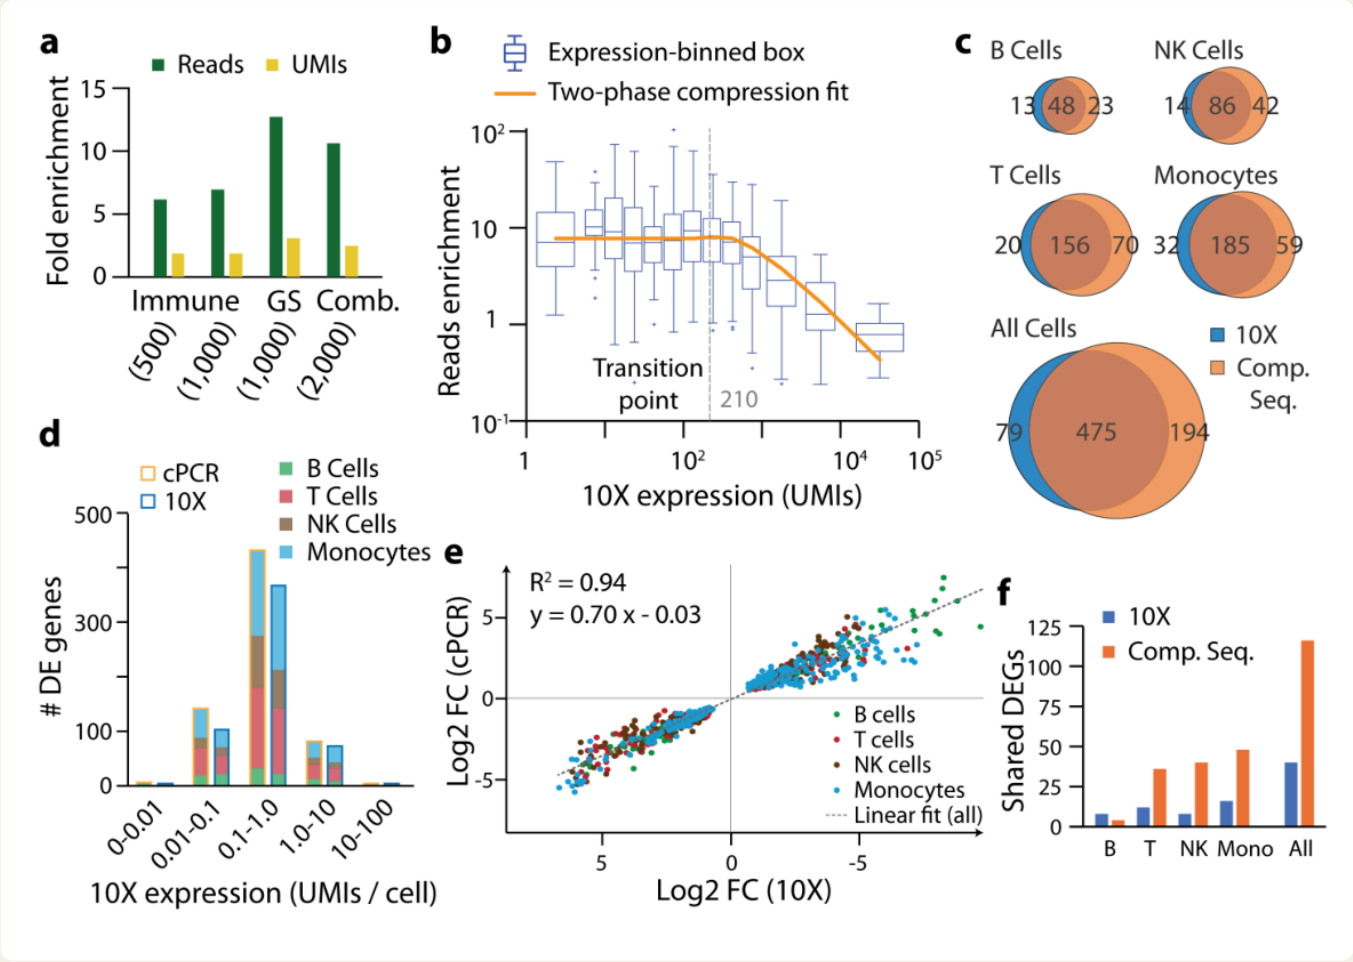
[推断] 这套机制解释里最弱的一环是 **"逐基因的 a、b 相同"**。公式对每个基因都成立，但 a（斜率）与 b（截距）实际由引物对的扩增效率、Tm、二聚体倾向决定。作者用"能量平衡引物 + 逐对热力学优化"压低这种差异，并用掺入参考序列做浓度校准 原文 p.4↗，但本 PDF 没有给出"96 个靶标的 a、b 分布"。Fig. 1l 里 96 条线并不完全重合（带宽较宽），提示逐基因差异是真实存在的——这也是为什么后面的单细胞比较都是"逐基因 vs 10X 的同基因"，而不是"跨基因比较绝对水平"。

第三张图：2,000 基因面板与"更有底气的 DEG"

500 基因面板证明"能压"，2,000 基因面板要证明"压完还能做真正的免疫学分析"。面板构成：**2,086 个免疫标记/签名基因**，合计占 10X 文库总丰度的 **18.7%**；拆成 4 个约 500 基因的子面板并行做，其中 186 个靶标在四个子面板里重复出现，用来做跨面板一致性检验 原文 p.6↗。压缩文库测到 **51 M reads（约为参考的 1/3）**。

结果的关键数字：读段从高丰度端向低丰度端重新分配（高丰度 **4.4×** 减少、低丰度 **5.1×** 富集）；稀有基因获得 **10.6× reads / 2.5× UMIs**；动态范围压缩 **30×**；UMI 覆盖 **67% vs 27%** 原文 p.6↗。这些与 500 基因实验方向一致、量级略有差异，说明压缩行为随 panel 规模变化但不会失效。

• FIGURE 3　原文 Figure 3 · p.6 · 混合裁切 · 来自 PDF 原始页面 · 1184×842 px　原文 p.6 ↗



原文图注 · P.6

"Figure 3. Comprehensive immune profiling in a 2,000-gene panel allows ultra-sensitive and reproducible DEG analysis"

逐面板解读

A　**不同面板规模下的富集倍数**：四组柱（Immune 500、Immune 1,000、Gene Signature 1,000、Combined 2,000），绿=reads、黄=UMIs。读数：reads 富集约 **6× / 6.8× / 12.5× / 10.6×**，UMIs 约 **2.1× / 2.0× / 3.1× / 2.5×**。注意 **reads 富集明显高于 UMI 富集**——因为"多读段"并不能自动变成"多分子检出"，这一差距本身就是方法的天花板（见 i 面板的随机抽样项）。原文 p.6 ↗

B　**富集倍数 vs 表达丰度**：横轴 10X 表达（UMIs），纵轴富集倍数（log）。低丰度端富集约 6–10×，随丰度升高下降，**过渡点标在 210 UMI**；高丰度端降到 1 以下（即"被压缩"）。这张图是 500 基因面板 Fig. 2h 的复现，说明两段行为不是单次实验的偶然。原文 p.6 ↗

C　**DEG 重叠（核心图）**：五个 Venn，分别对应 B / T / NK / Monocytes / All cells；蓝=仅 10X，橙=仅压缩，中间=共有。读数：B 13/48/23、T 20/156/70、NK 14/86/42、Mono 32/185/59、All **79/475/194**。合计 DEG 从 **554（10X）** 增加到 **669（压缩）**，即 **+21%**。四个细胞类型分别为 +12% 到 +28%（原文 p.6）。原文 p.6 ↗

D　**多出来的 DEG 在哪个丰度段**：横轴是 10X 的每个细胞 UMI 丰度分箱（0–0.01、0.01–0.1、0.1–1.0、1.0–10、10–100），纵轴 DEG 数，颜色分细胞类型，橙框=cPCR、蓝框=10X。关键读数：**增量几乎全部落在 0.1–1.0 UMI/cell 这一箱**（<1 个 UMI 的基因在 10X 里本来就没法稳定检出）。这正面回答了"多出的 DEG 是不是靠不住的低表达基因"——是低表达基因，但恰恰是压缩声称要救的那一段。原文 p.6 ↗

E **共享 DEG 的效应量一致性**：横轴 10X 的 Log2FC，纵轴压缩后的 Log2FC；图内标注 R^2=0.94，拟合 **y = 0.70x − 0.03**。注意：**正文同一处写的是"Log2FC R^2=0.98"**（p.6），与图内 0.94 不一致；正文还并列引用了 Extended Data Fig. 3p，两个数字可能来自不同比较，但本 PDF 无法核对 [推断]。这是全文最重要、也最被轻描淡写的一个数字：**斜率 0.70 意味着压缩后的效应量整体被衰减约 30%**。作者解释为"10X 在近零 UMI 时比值膨胀"原文 p.6↗，但压缩本身也会衰减 log 尺度上的差异（见第 11 节）。原文 p.6↗

F **跨样本可重复性（全文最巧的对照）**：同一套流程在两个生物学独立供体上各做一次标准 + 压缩测序，取"两个样本都检出"的 DEG 数。读数：B 约 5 vs 10、T 约 38 vs 14、NK 约 40 vs 10、Mono 约 50 vs 18、合计 **约 115 vs 40**（压缩 vs 10X）。更关键的是重叠率：**压缩独有的 DEG 在两个供体间重合 45%，而 10X 独有的只重合 21%** 原文 p.6↗。如果压缩多出的 DEG 是噪声，跨供体不该重合——这是"多出来的 DEG 是真的"最有力的间接证据。原文 p.6↗

读图注意：C 与 E 面板的两处"技术性陷阱"

① **Venn 图的数字不能直接相加比较"谁更强"。**"仅压缩检出"的 194 个 DEG 中，会有一部分在更深的 10X 里也能检出（只是没达到显著阈）；反过来，"仅 10X"的 79 个在压缩里可能是引物失败或压缩后 UMI 太少。真正可比的是"在**相同测序预算**下谁多"——而这点本文是用"1/3 深度 vs 全深度"做的，属于对压缩有利的不对称比较。

② **斜率 0.70 不是小事。**如果读者要把压缩数据直接塞进现成的差异分析流程、并沿用同一套 fold-change 阈值（比如 |log2FC|>1），**压缩数据会系统性地更难通过阈值**。原文只在讨论里用一句"ratio inflation"带过，没有给出校正方案——这是本 PDF 主文里最明显的一个"未完成接口"。

为什么我认为 F 面板是这篇论文最该被同行学走的设计

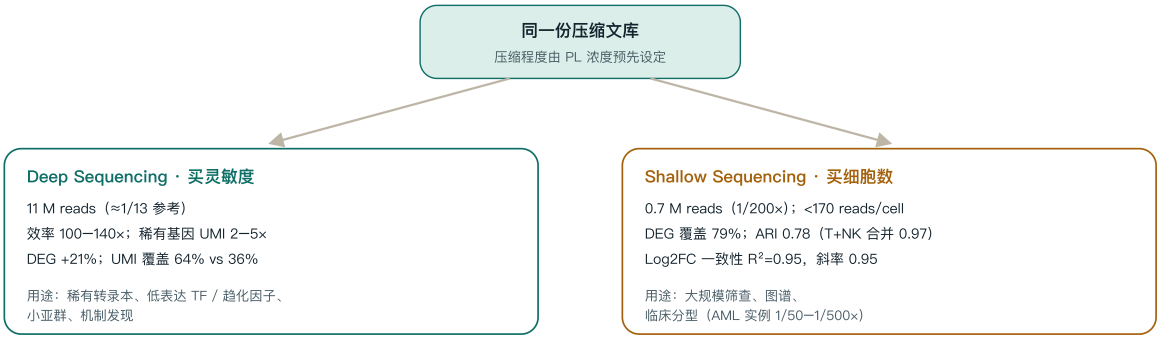
"我的新方法检出更多差异基因"是单细胞方法论文里最廉价的主张，因为更深的测序、更宽松的阈值、更大的细胞数都能做到。本文的 45% vs 21% 提供了一个**不依赖 ground truth 的判别器**：如果新增检出是真信号，它应该在独立生物学重复里重现；如果是噪声，重现率会掉到随机水平。这个对照不需要额外的湿实验，只需要再做一次样本 —— 任何声称"更灵敏"的方法都应该补这一张图。

09

第四张图：把省下来的深度花在"更多细胞"上

同一套化学可以往另一个方向用：不追求"更深"，而是把压缩带来的效率换成"更浅但更多"。作者把 500 基因面板的压缩文库只测到 **0.7 M reads**——相对 140 M 的参考是 **1/200×**，相当于每个细胞 **<170 reads** 原文 p.7↗——然后问：这么浅还能不能分细胞、找 DEG?

◆ AI 重绘示意图（非原文图）　两种用法对照 · 数字转录自 p.4–8 正文

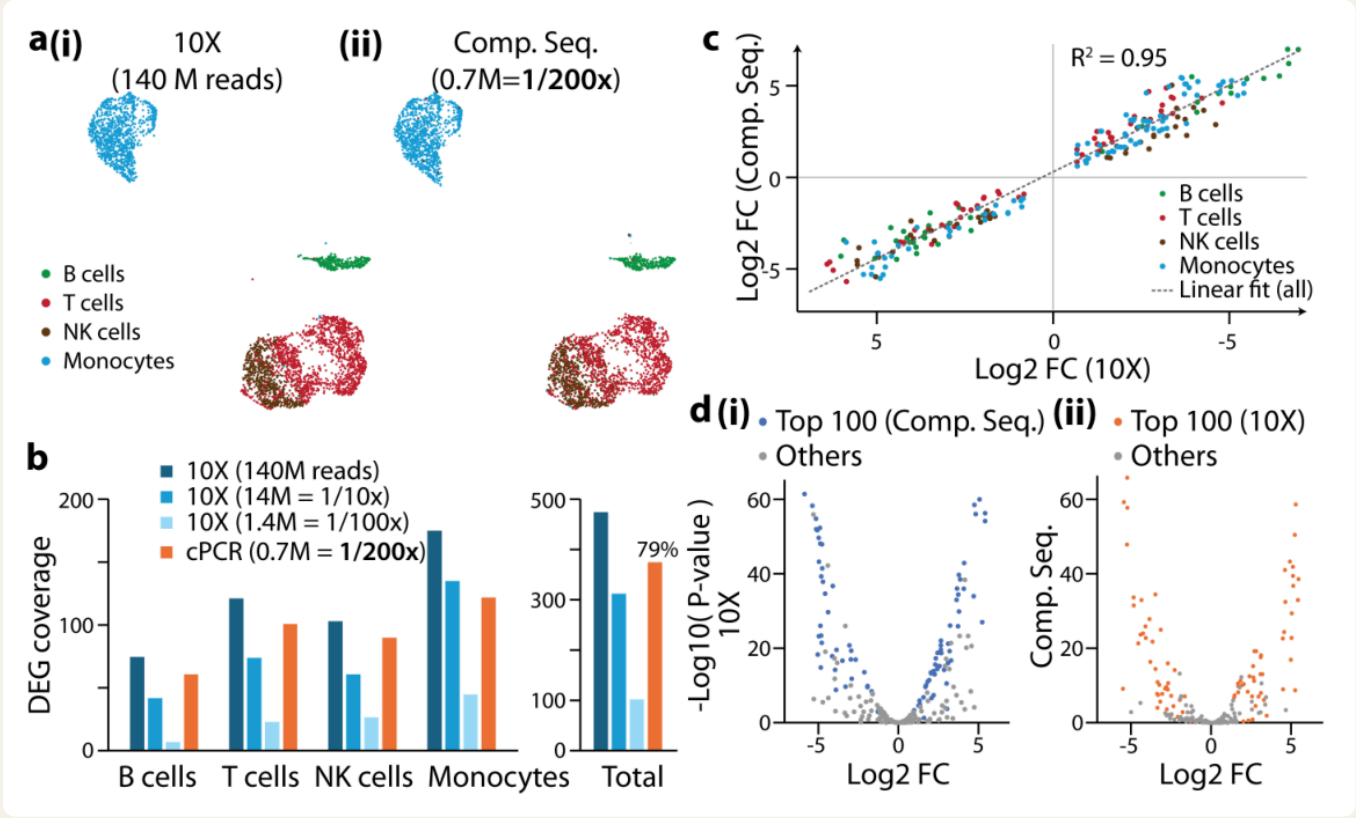


AML：600–800 reads/cell（1/50–60×）ARI 0.80–0.82；下采样到 80 reads/cell（1/500×）仍 85–92% 准确率

同一化学、同一 panel：选择"测多深"等于选择"买灵敏度还是买样本量"

读法：这不是两种方法，而是同一个方法的两个操作点。作者的核心卖点也在这里——**压缩把"深度"从硬约束变成了可调参数**。但也因此，Deep 与 Shallow 的所有数字都绑定在"500–2,000 基因 panel"这个前提下，不能外推到全转录组（作者自己把全转录组列为 future work）。

• FIGURE 4　原文 Figure 4 · p.7 · 混合裁切 · 来自 PDF 原始页面 · 1167×706 px　原文 p.7 ↗



原文图注 · P.7

"Figure 4. Compressed "Shallow Sequencing" with 200x lower depth enables ultra-scalable scRNA-seq"

逐面板解读

A　**UMAP 对比**：(i) 是 10X 全深度（140 M reads），(ii) 是压缩浅测（0.7 M，1/200×），坐标是同一套投影。四类细胞（B、T、NK、Monocytes）位置基本一致——**但要注意 (ii) 是把压缩数据"映射"到 10X 的投影上**，不是独立降维后再比，所以这张图证明的是"标签可迁移"，不是"独立聚类得到同样结构"。原文 p.7 ↗

B　**DEG 覆盖（最有信息量的柱状图）**：四组柱分别是 10X 全深度、10X 1/10×、10X 1/100×、cPCR 1/200×。读数：B 细胞四组约 75 / 40 / 8 / 55；T 约 125 / 75 / 20 / 100；NK 约 100 / 55 / 20 / 90；Monocytes 约 170 / 135 / 45 / 130；Total 约 470 / 310 / 95 / **370（79%）**。关键对比：**cPCR 在 1/200× 的深度下，DEG 覆盖超过了 10X 在 1/10× 的深度、远高于 1/100× 的 10X（<15%）**。这比"跟全深度比"公平得多。原文 p.7 ↗

C　**效应量一致性**：共享 DEG 的 Log2FC 对比，R^2=0.95、斜率 0.95。注意与 Fig. 3e 的对比：**浅测模式的斜率是 0.95，深测模式是 0.70**。同一方法、同一 panel，斜率随深度变化——这提示斜率 0.70 更可能与"高丰度基因在深测模式下被压缩"有关，而不只是 10X 的比值膨胀（见第 11 节）。原文 p.7 ↗

D　**火山图互检**：(i) 是 10X 的火山图，(ii) 是压缩的火山图；蓝点 = 压缩检出的 top 100 基因，(ii) 里橙点 = 10X 检出的 top 100，灰点是其余。两侧的"对方 top 100"都落在自己火山图的显著臂上，说明**两种方法挑出的强信号高度互认**。这是一个 rank-based 的一致性检验，不做绝对阈值假设。原文 p.7 ↗

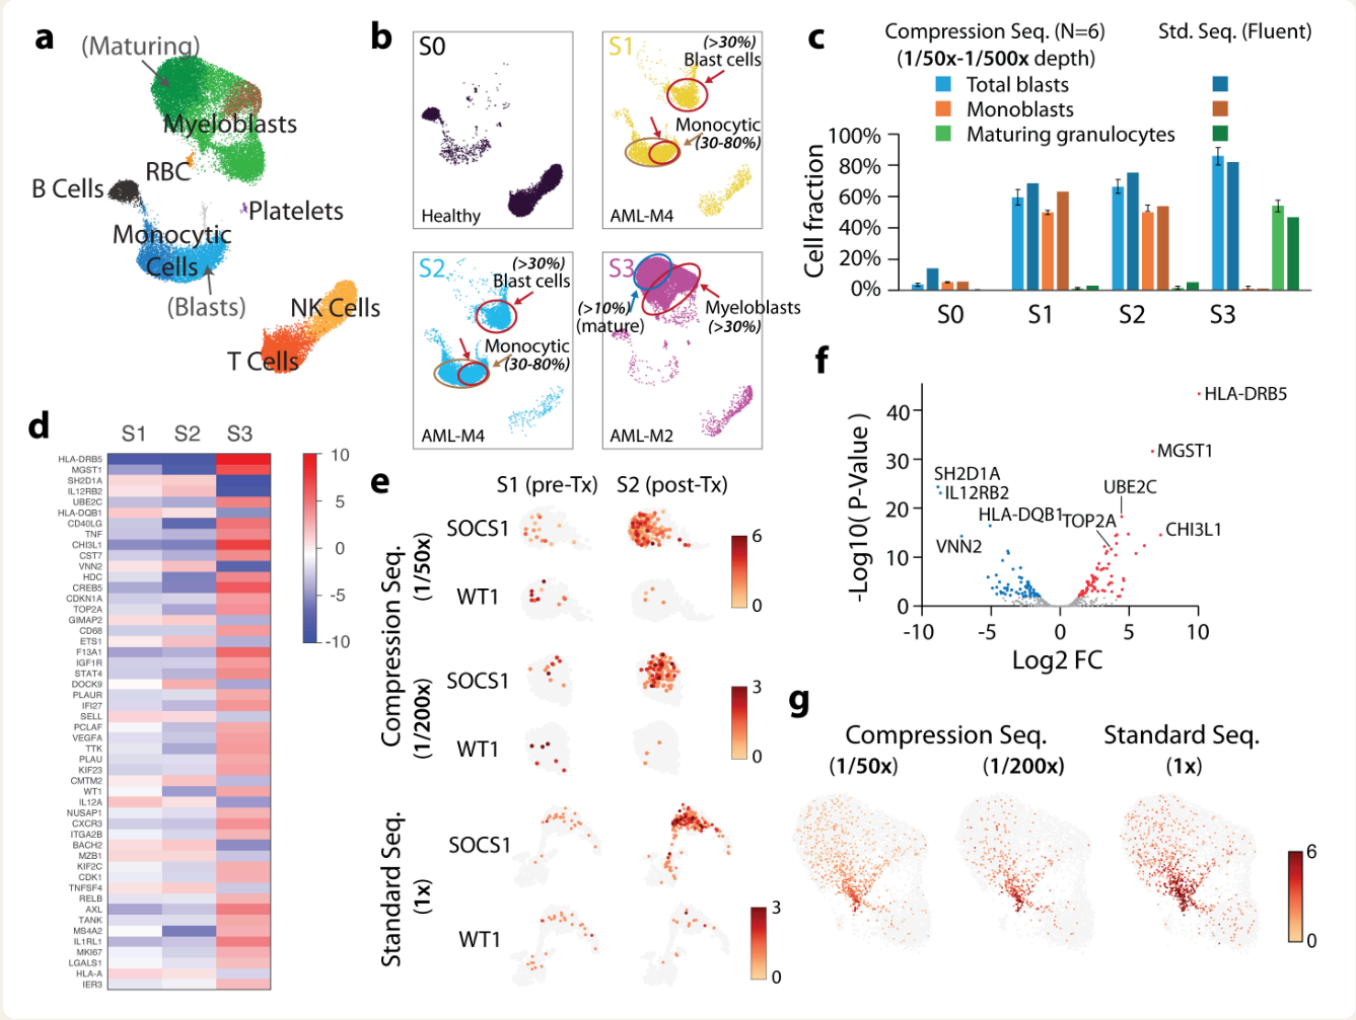
读图注意： B 面板的对照设计值得学，但有一个口径要问清楚

b 面板是全文唯一把"同等深度下的 10X 下采样"和"压缩"放在一起比的地方，这是正确的对照思想。但 **1/100× 的 10X 与 1/200× 的 cPCR 并不是"同等深度"**——前者是 1.4 M reads、后者是 0.7 M reads；cPCR 用更少的 reads 拿到更多 DEG，这才是它的主张。真正严格的对照应该是"1/200× 的 10X 下采样"，原文这里取的是 1/100×（对 10X 稍有利，因此不构成夸大）。另外，ARI=0.78 不算高，原文也承认要靠"合并 T 与 NK"才到 0.97——**这说明 panel 在浅测时最难分辨的是 T/NK 这类转录组相近的细胞**。

10

第五张图：AML 临床样本，把"$10/样本"摆上桌

这是全文的"落地"章节，也是样本最薄、主张最大的一章。设计：3 例 AML 患者（S1、S2 为 M4，S3 为 M2）+ 1 例健康对照（S0），用 Fluent（Illumina）的 PIP-seq 做无微流控 barcoding 原文 p.7↗；先按标准深度测参考（**38,000 reads/cell**），再对同一文库做压缩 + 浅测（**600–800 reads/cell，1/50–60×**），并进一步下采样到 **80 reads/cell（1/500×）** 原文 p.7–8↗。分析面板是 1,000 个免疫标记基因（952 基因 / 1,084 靶标）。



原文图注 · P.8

"Figure 5. Compression Sequencing enables affordable AML diagnostics with in-depth transcriptomic analysis"

逐面板解读

A **四个样本共聚类的 UMAP**：标注了髓系（成髓细胞、成熟中的粒细胞）、单核细胞系、B / T / NK、红系（RBC）与血小板（Platelets）。三个 AML 样本的病理性母细胞（blasts）明显**溢出到健康细胞群之外**——这是复现"疾病状态"的第一层证据。原文 p.8↗

B **逐样本 UMAP 与 FAB 判据**：S0（健康）无异常亚群；S1、S2 标出 **>30% blasts、30–80% 单核细胞**（AML–M4 判据）；S3 标出 **>30% blasts、<20% 单核、>10% 成熟粒细胞**（AML–M2 判据）。这些百分比判据来自 FAB 分类 原文 p.7↗，作者用转录组 marker 把细胞分类后计算比例，再与判据比对。原文 p.8↗

C **细胞比例 vs 深度 vs 标准测序**：三组柱（总 blasts、单核母细胞、成熟粒细胞），压缩侧是 **N=6**（1/50×…1/500× 六个深度），标准侧是 Fluent 参考。读数：S1 的 blasts 约 59% vs 68%、单核约 48% vs 62%；S2 约 66% vs 76%、51% vs 53%；S3 的 blasts 约 85% vs 81%、成熟粒细胞约 53% vs 46%。**趋势与量级都对得上，误差棒是跨深度的标准差**（不是生物学重复）。原文 p.8↗

D **母细胞的 top-50 DEG 热图**：三个 AML 样本的母细胞差异表达谱，行是基因（HLA-DRB5、MGST1、SH2D1A、IL12RB2、UBE2C、HLA-DQB1、CD40LG、TNF、CHI3L1、CST7、VNN2...），列是 S1/S2/S3。S3 与 S1/S2 的谱明显不同（S3 在 HLA-DRB5、MGST1、UBE2C 一列高），与"不同亚型/不同克隆"一致。原文 p.8↗

E **治疗前后与深度的三角验证**：SOCS1 与 WT1 两个基因，在 S1（治疗前）vs S2（治疗后）的母细胞上，分别用 **1/50× / 1/200× / 标准 1×** 三种深度展示。**SOCS1 在治疗后明显上调**（提示治疗诱导的转录调节，且未见母细胞清除），**WT1 轻度下调**（MRD 标志物，提示治疗有效）——两个方向相反的变化在三种深度下都成立，这是本文最有临床意义的一处观察。原文 p.8↗

F **M2 样本（S3）母细胞的火山图**：上调端标注 HLA-DRB5（提示免疫调节）、MGST1、UBE2C、CHI3L1（与干性/不良预后相关），左端是下调基因（VNN2、SH2D1A、IL12RB2 等）。原文 p.8↗

G **找到"活跃周期"亚群**：用 MKI67 等细胞周期基因在 UMAP 上标出一个增殖亚群，三张图分别是压缩 1/50×、压缩 1/200×、标准 1×——**三者在浅测下仍能定位到同一个亚群**。作者据此提出"增殖压力 / 残留病风险"的解释。原文 p.8↗

读图注意：临床结论的四个"不足以"

① **n=3 不足以谈"复现诊断准确率"。**3/3 与随机猜对（1/2 或 1/3）在统计上无法区分；原文没有报告任何敏感性/特异性区间。

② **判据是"转录组代理形态学"。**FAB 的 M4/M2 判据原本基于形态学与细胞化学（原始细胞比例、单核细胞比例、成熟粒细胞比例），本文用 marker 基因注释出的细胞类型去算这些比例，**没有报告与病理科盲法判读的一致性**。这既可能是优势（可自动化），也可能是循环论证（用同一套表达数据证明表达数据分类正确）。

③ **图 c 的误差棒是 N=6 个测序深度，不是 6 个患者或 6 次独立实验**，所以它衡量的是"深度稳健性"，不是"生物学可重复性"。

④ **没有随访 / MRD 终点。**SOCS1 上调被解释为"治疗诱导的转录调节"，WT1 下调被解释为"治疗有效"，但没有任何临床结局（缓解、复发、生存）来验证这两句话——它们目前只是**与已知生物学一致的观察**，不是疗效预测的证据。

这一章真正的价值：把"单细胞诊断"的成本门槛具象化

无论 n 多小，"600–800 reads/cell 就能复现 M2/M4 的分型"这句话如果成立，它改变的是**单细胞进入临床的经济学**：作者估测测序成本 <$5/样本（2–3 万细胞），连同 barcoding 的"每患者 <$10" 原文 p.8↗。这个数字是全文最容易被引用、也最需要打折扣的结论——它只算测序与 barcoding，**不算 1,000 对引物的合成验证、不算建库人力、不算临床样本处理与合规成本**。不过即使打上几倍折扣，它仍然把"单细胞诊断"从"科研项目"推向"可负担检测"的量级。

11

批判性评估：它成立到什么程度

这篇论文的论证结构其实很清晰：**化学（cPCR 是 log 编码器）→ 文库（压缩能接在 10X 上）→ 生物学（压缩数据能做常规分析）→ 临床（浅测也能分型）**。四段里，第一段最硬，第四段最弱。下面按"强项 / 不确定 / 不能外推"三类拆。

站得住的部分

- **核心化学被独立、定量地验证。**公式有推导、两相有实时曲线、5 个数量级的端点线性 R^2=0.99、96 重与 192 重（双物种）交叉验证。这是"分子对数编码器"这一提法能立住的地方 原文 p.3–4↗。
- **两段模型把机制和数据接上了。**低丰度线性、高丰度对数，过渡点可估计——这解释了"为什么压缩只作用于高丰度基因"，而且预测与数据方向一致 原文 p.5↗。
- **不回避代价。**Fig. 2j 主动展示 CD52 这类高丰度基因压缩后 UMI 减少；Fig. 2f 显示压缩只在 panel 内部带来 2–5× 的读段再分配。这种"把不利数据放进主图"的做法在方法论文里不常见。
- **DEG 真实性的内部对照设计得很好。**用两个独立供体的"仅压缩检出 DEG"重现率（45% vs 21%）来反驳"多出来的都是假阳性"，这比单看 DEG 数更有说服力 原文 p.6↗。
- **add-on 设计降低采纳门槛。**barcode 在压缩前已打好，因此可与标准测序**配对比较**——本文所有"逐细胞、逐基因"的论证都建立在这一点上 原文 p.4↗。
- **可调性是真的可调。**同一套化学从 Deep（11 M）到 Shallow（0.7 M）到 AML（600 reads/cell）到 80 reads/cell，覆盖两个数量级的深度并逐级报告退化 原文 p.4–8↗。

不确定处 / 需要补充的证据

- **没有 "panel-only、不压缩" 的消融。**headline 的 100–140× 效率是"只测 457 个基因"与"压缩"两件事的乘积；panel 本身的读段集中效应有多大，原文没有单独测。而 Fig. 2f 里可归因于压缩的读段再分配只有 2–5×。这是全文最大的归因缺口 原文 p.5↗。
- **报告口径有一处小矛盾。**同一段话里正文给 Log2FC 的 R^2=0.98，而 Fig. 3e 图内标注 R^2=0.94；两处都没有说明是哪一组比较。这类细节不影响主结论，但提示读者：正文数字与图内数字应逐一对表后再引用 原文 p.6↗。
- **Log2FC 斜率 0.70 没有解释清楚。**作者归因于 10X 在近零 UMI 时的比值膨胀；但同一方法的浅测版本斜率是 0.95，说明"深度/压缩段位"会影响斜率。没有校正方案，也没有讨论这对沿用固定 |log2FC| 阈值的下游流程意味着什么 原文 p.6↗。
- **跨基因定量是否被破坏，主文没说清。**压缩是逐基因的单调变换，但每个基因的 a、b 不同；因此"同一细胞内基因 A 与基因 B 的读段比"被改写。作者用标准流程做归一化与分型，并显示分型没问题，但没有给出"何时可以、何时不可以把压缩矩阵当普通表达矩阵用"的判据。
- **过渡点与参数的可迁移性。**370 reads / 150 UMIs 是在特定 panel、特定细胞数、特定 PL 浓度下拟合的；换 panel 或换组织是否需要重新标定？原文把方法细节放进 Supplementary Note 3，而本 PDF 不含该文件。
- **引物失败的偏差方向。**96 重成功率 72%、500 基因引物成功率 93%。失败的靶标是否集中在高 GC、长转录本、低表达或特定 isoform？如果是，panel 的"无偏"就会打折扣 原文 p.4↗。
- **成本模型缺失。**"<$5 测序 / <$10 每患者"只含测序与 barcoding；500–2,000 对引物的合成、验证、平衡与人力成本没有列支，也没有与"直接加深测序"做成本–效果比较 原文 p.8↗。

薄弱点 / 不能外推的地方

- **样本面窄。**PBMC 两个供体（Fig. 2–4 主要是 1 个供体，第 2 个供体只用于 DEG 重复性）；AML 3 例；全部是血液样本。作者称"适用于骨髓等"，但本 PDF 没有数据 原文 p.4–8↗。
- **不是全转录组。**所有实验都在 457–2,086 个基因的 panel 上；作者把"whole-transcriptome coverage"列为 future work 原文 p.9↗。这意味着它目前是"targeted panel 的增强版"，而不是"scRNA-seq 的通用替代"。
- **临床结论没有独立金标准。**AML 亚型判读用 FAB 形态学标准，但本文的"细胞类型"来自转录组 marker；没有病理科盲法复核、没有流式/形态学对照、没有随访终点 原文 p.8↗。
- **没有与竞争方法头对头。** hybridization normalization、DSN、targeted Perturb-seq / HyPR-seq 都只在引言里被一句话带过，没有在同一文库上做对比。因此"比现有方法好多少"无法从本文判断 原文 p.2↗。
- **新检出的 DEG 没有正交验证。**没有 qPCR、流式或蛋白层面的确认；"额外 DEG 是真的"完全依赖跨供体重现率这一间接论证（虽然这个论证相当有力）原文 p.6↗。
- **预印本。**本 PDF 是 bioRxiv 预印本（2026-09-03 上传，CC-BY-NC-ND 4.0），未经同行评审；Methods 与补充材料不在本文件内，关键实验参数无法核对。

三个必须自己回答的问题

1. **100× 里有多少来自 panel、多少来自压缩？**要回答这个问题只需要一个对照：同一 panel 做普通 PCR 富集（不压缩）测到同样深度，看每基因读段与 UMI。本文没有做。按 Fig. 2f 的数字，压缩本身在 panel 内只贡献 2–5× 的再分配，其余来自"只测 1/40 的基因" [推断]。
2. **压缩后的表达矩阵还能不能直接喂给现有流程？**Log2FC 斜率 0.70 说明"能，但效应量被压缩"；如果下游用固定 fold-change 阈值，需要重新标定，或者用两段模型反解回线性尺度。本文没有给出这个"反解层"——这是方法从"论文"走向"工具"必须补的一块。
3. **换组织、换平台、换物种还成立吗？**cPCR 的化学是通用的，但过渡点、引物成功率、on-target 比例都与样本复杂度、RNA 完整性、barcoding 平台有关。本文只给了血液 + 10X/Fluent 的组合，跨体系的验证是空白。

[推断] 一个替代解释：收益可能被"PANEL 选择"高估

如果把 2,000 基因 panel 拿去做普通靶向富集（不加压缩、不做两段扩增），在 51 M reads 下也很可能拿到远高于全转录组 10X 的 UMI 覆盖——因为 81.3% 的文库丰度被排除在外。这意味着本文报告的"效率提升"里，有一块属于**靶向测序本身的收益**，而 cPCR 的独特贡献是"panel 内部把读段从高丰度挪到低丰度"这一块（2–5×）。这不妨碍方法的实用性（组合起来确实省），但会改变"这项技术有多革命性"的判断，也会改变读者该把资源投向"设计更好的 panel"还是"引入压缩"。

与我相关：可以借走的三样东西

如果只把这篇论文记成"一种新的单细胞建库方法"，会漏掉它真正可迁移的部分。至少有三样东西与具体化学无关：

一、"用饱和机制实现非线性"的工程范式

cPCR 的聪明之处不是"发明了对数"，而是**用一管限量引物把"什么时候饱和"变成了输入的函数**。这个范式可以搬到任何"试剂有限、读出是终点值"的体系：定量 PCR、等温扩增、ELISA 的显色终点、甚至液滴里的荧光报告。判据是：只要体系里存在一个**可被耗尽、且耗尽时刻取决于输入浓度**的组分，终点读出就能被设计成对数或任意压缩函数。对做检测/传感/筛选的人来说，这比"又一个 scRNA-seq 方法"更通用。

二、"两段模型 + UMI 层面解剖"的验证套路

本文没有停留在"压缩后信号 vs 原来信号 R^2=0.9"，而是把关系拆成两段、给出过渡点、再用 UMI 交集逐基因检查（Fig. 2j）。这套"先拟合、再在分子层面抽 8 个基因逐个看"的验证方式，可以直接用在任何"改变了测量映射"的方法上（例如新的 UMI 去重策略、新的扩增方案、新的建库化学）——因为**聚合指标（中位数、R^2）会掩盖分段行为**，而分段行为恰恰决定了方法在哪个丰度段可用。

三、"跨样本重现率"作为真阳性判别器

Fig. 3f 的 45% vs 21% 是整篇论文里最便宜、最有说服力的对照：不需要 ground truth，只需要两个独立生物学重复，就能判断"新增检出"是真信号还是阈值放宽的产物。任何声称"更灵敏"的方法（更深的测序、更好的归一化、新的细胞分型算法）都可以照搬这个判别器，成本只是再做一次样本。

> **如果要把这篇论文变成一条可执行的实验路线**
>
> [推断] 最低风险的路径是：在**已有的 10X 或 PIP-seq 文库**上做一个 200–500 基因的 panel（选你最关心的低丰度通路，而不是全免疫 panel），用本文的 add-on 流程做一次压缩 + 一次标准测序配对；先只验证三件事——(1) 两段模型在你的体系里是否出现；(2) 你最关心的 10–20 个稀有基因的 UMI 是否真的提高；(3) 你熟悉的 marker 分型是否保持。三件都过，再考虑把它推到大规模筛查或临床样本。风险最高的一步是"全转录组压缩"，因为那需要几千对引物同时在复杂背景里工作，而本文自己也把它留给了未来。

另外值得留意的是它与其他方向的接口：本文的 AML 部分已经用了 Fluent 的无微流控 barcoding（PIP-seq）原文 p.7↗，这意味着"压缩化学"与"低成本 barcoding"可以叠加；而它与液滴微流控、AI 虚拟细胞训练数据这两条线的关系，作者在讨论里都点了名 原文 p.9↗——前者是"更多细胞"，后者是"更高质量的表达谱"，压缩对两者都只是**降成本**，不改变数据的基本形态，因此接入成本低。

13

术语表

cPCR（Compression PCR）

本文的核心反应：用不等量正反向引物（过量 PE / 限量 PL）制造"指数相 + 线性相"两段扩增，使终点产物与模板浓度的对数成正比。

PE / PL

excess primer（过量引物）/ limiting primer（限量引物）。PL 被耗尽的时刻决定压缩程度，PE/PL 比是主旋钮。

非对称 PCR / LATE-PCR

asymmetric PCR；LATE-PCR 是其中一种用于实时定量的变体。本文的差别在于刻意拉长第二相并把它当作定量区间。

动态范围（dynamic range）

同一个测量里最大值与最小值的比值。scRNA-seq 里 mRNA 丰度跨 5–6 个 log，是"读段被高丰度基因吃掉"的根源。

对数变换 / 压缩

把输入按 log 映射到输出。本文用分子反应实现：输入 10^5 倍 → 输出 <10 倍。

两段模型（two-segment model）

低丰度段线性放大（PL 未耗尽）、高丰度段对数压缩（PL 提前耗尽），中间有过渡点。本文用它在 reads 与 UMI 两个层面拟合（Fig. 2h–i、Fig. 3b）。

UMI / barcode

unique molecular identifier（分子条码，用于去重计数）/ cell barcode（细胞条码，用于归属细胞）。压缩必须保留这两者才能回到单细胞。

dropout

某个基因在某个细胞里实际有表达、但因抽样没被测到（计数为 0）的现象。低丰度基因 dropout 率可达 50–100%。

饱和度（saturation）

测序深度增加到一定程度后，再测也主要是重复读到同样的分子；本文用它来比较"达到同等饱和度需要多少 reads"。

preseq

用已有测序数据外推"文库复杂度"与"还需要多少 reads"的软件（Daley & Smith, 2013）。本文用它估计压缩后文库复杂度降低约 100×。

on-target rate

落在目标区域（panel 基因）上的读段比例。嵌套 PCR 把它从 40% 提到 70%。

panel / 靶向测序

只扩增/捕获预先选定的一组基因。本文所有单细胞实验都是 panel 形式（457–2,086 个基因），不是全转录组。

ARI（adjusted Rand index）

两种聚类划分的一致性指标，1 = 完全一致，0 ≈ 随机。本文浅测分型 ARI=0.78（四类），合并 T/NK 后 0.97。

DEG / Log2FC

differentially expressed gene（差异表达基因）/ $\log_2$ 倍数变化。本文报告压缩后 DEG 多 21%，但 Log2FC 斜率只有 0.70。

FAB 分类

French–American–British 的 AML 形态学分型（M0–M7）。M4 = 急性粒单核细胞白血病（30–80% 单核细胞），M2 = 伴成熟粒细胞的急性髓系白血病。

MRD

measurable residual disease，可测量残留病。本文用 WT1 表达变化提示 MRD，但没有随访数据。

PIP-seq

Fluent（现 Illumina）的无微流控单细胞 barcoding 方法（templated emulsification），成本低于液滴微流控。本文 AML 部分用它建库。

Harmony

常用的单细胞批次整合算法。本文用它把 Fluent 与 10X 的样本共聚类。

14

引用与延伸阅读

本报告页码均指所提供 PDF 的页面（共 11 页：主文 p.1–9，参考文献 p.10–11）。原文为 bioRxiv 预印本，DOI `10.64898/2026.09.01.748706`，2026-09-03 上传，CC-BY-NC-ND 4.0，未经同行评审；Methods 与 Supplementary 不在本文件内。

1. Yan, Y. & Dai, M. *Compression Sequencing enables ultra-sensitive and scalable scRNA-seq*. bioRxiv (2026). doi:10.64898/2026.09.01.748706 —— 本文。Rice University 生物工程系 / 化学系，通讯作者 mingjie.dai@rice.edu。

1. Sanchez, J. A., Pierce, K. E., Rice, J. E. & Wangh, L. J. Linear-after-the-exponential (LATE)-PCR: an advanced method of asymmetric PCR and its uses in quantitative real-time analysis. *PNAS* 101, 1933–1938 (2004). —— cPCR 的直接前身：非对称 PCR 用于定量。
2. Gyllensten, U. B. & Erlich, H. A. Generation of single-stranded DNA by the polymerase chain reaction. *PNAS* 85, 7652–7656 (1988). —— 单链扩增的原始方法。
3. Shannon, C. E. & Weaver, W. *The Mathematical Theory of Communication*. University of Illinois Press (1949)；Huffman, D. A. *Proc. IRE* 40, 1098–1101 (1952)；Golomb, S. W. Run-length encodings. *IEEE Trans. Inf. Theory* (1966). —— 作者用来支撑"压缩"这一信息科学类比的经典文献。
4. Larson, G. W. LogLuv Encoding for Full-Gamut, High-Dynamic Range Images. *J. Graphics Tools* 3, 15–31 (1998). —— 对数编码在高动态范围图像里的先例。
5. Xie, N. G. et al. Designing highly multiplex PCR primer sets with Simulated Annealing Design using Dimer Likelihood Estimation (SADDLE). *Nat Commun* 13, 1881 (2022). —— 本文引物设计算法的来源；作者称二聚体形成比该报道降低 >10×。
7. Daley, T. & Smith, A. D. Predicting the molecular complexity of sequencing libraries. *Nat Methods* 10, 325–327 (2013). —— preseq 软件，本文用它估计文库复杂度下降约 100×。
8. Love, M. I., Huber, W. & Anders, S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biol* 15, 550 (2014). —— 作者用来解释 Log2FC 斜率偏低时引用。
9. Svensson, V. et al. Power analysis of single-cell RNA-sequencing experiments. *Nat Methods* 14, 381–387 (2017). —— 单细胞 dropout 与测序深度的定量分析，本文问题陈述的主要依据之一。
10. Zheng, G. X. et al. Massively parallel digital transcriptional profiling of single cells. *Nat Commun* 8, 14049 (2017). —— 10X 平台原始文献。
11. Clark, I. C. et al. Microfluidics-free single-cell genomics with templated emulsification. *Nat Biotechnol* 41, 1557–1566 (2023). —— Fluent PIP-seq，本文 AML 部分的建库方法。
12. Schraivogel, D. et al. Targeted Perturb-seq enables genome-scale genetic screens in single cells. *Nat Methods* 17, 629–635 (2020)；Marshall, J. L. et al. HyPR-seq. *PNAS* 117, 33404–33413 (2020). —— 本文引言里作为"靶向 panel 路线"的代表。
13. Replogle, J. M. et al. Mapping information-rich genotype-phenotype landscapes with genome-scale Perturb-seq. *Cell* 185, 2559–2575 (2022). —— 大规模 Perturb-seq 的成本与规模背景。
14. Hagemann-Jensen, M., Ziegenhain, C. & Sandberg, R. Scalable single-cell RNA sequencing from full transcripts with Smart-seq3xpress. *Nat Biotechnol* 40, 1452–1457 (2022). —— 作者在讨论里提出的"深测 + 微孔板"替代路线。
15. van Galen, P. et al. Single-Cell RNA-Seq Reveals AML Hierarchies Relevant to Disease Progression and Immunity. *Cell* 176, 1265–1281 (2019)；Döhner, H. et al. Acute Myeloid Leukemia. *N Engl J Med* 373, 1136–1152 (2015). —— AML 单细胞与临床背景。
16. Bennett, J. M. et al. Proposed revised criteria for the classification of acute myeloid leukemia (FAB). *Ann Intern Med* 103, 620–625 (1985). —— 本文亚型判读所依据的 FAB 标准。

原文最值得记住的三句

"Fundamentally, this is caused by the high dynamic range of mRNA expression in human cells."（p.2）—— 问题的根因一句话。

"…the second phase ('prolonged linear phase') reflects true linear growth due to single-primer amplification, which is different from the transient 'linear phase' observed in conventional qPCR assays."（p.2）—— 它与常规 qPCR 的分界线。

"…logarithmic compression suppresses read fraction from high-abundance genes by 40x while boosting that from low-abundance ones, achieving up to 500x overall improvement in sequencing efficiency and sensitivity in rare genes."（p.2，模拟结果）—— 注意这是 **in silico** 数字，实验值是 100 – 140×。

图表溯源附录 PROVENANCE

本报告的原文图均为论文 PDF 页面按坐标裁切的高分辨率渲染（非 AI 生成）；图中文字与面板标记保留自原文。裁切框单位为 PDF point（1/72 inch），原点在页面左上角。

图号	页码	裁切框 (pt)	检测	尺寸	文件
Figure 1	p.3	85.0, 104.8, 529.9, 551.0	mixed	1360×1364	fig1.png
Figure 2	p.5	33.2, 169.6, 579.0, 572.3	image	1600×1182	fig2.png
Figure 3	p.6	113.1, 351.1, 500.4, 626.1	mixed	1184×842	fig3.png
Figure 4	p.7	115.7, 39.0, 497.1, 269.9	mixed	1167×706	fig4.png
Figure 5	p.8	86.2, 41.8, 522.5, 370.8	mixed	1334×1006	fig5.png

证据分级：**证据标记** 指向原文页码/图号或本报告图表；「AI 重绘示意图」为基于原文文字/图表的解释性重绘，不代表原始数据；未标注来源的判断为解读性推断。

源文件：work/cseq/paper.pdf | **PDF SHA-256**：8a2a855c21a5166f301a70cfaa4af6831a3d487e82ac469bdf7b6525a35a0868 | **页数**：11 | **收录图表**：5 | **生成**：2026-10-28 | **工具**：paper-deepread-html（PyMuPDF 裁切 + 单文件内嵌 + 纯 JS/SVG 重绘）

原文 PDF：查看 | RAW-2026-bioRxiv-Compression Sequencing enables ultra-sensitive and scalable scRNA-seq.pdf